Crawler API 使用教學

更新時間: 2022/06/19

- API 簡介

  使用者會在各個史料平台上挑選資料，並把這些資料在平台上匯集下載。此 API 會以這些資料為目標進行爬蟲，以用來取得更多 metadata 的細節。此 API 會接受從各個史料平台上下載的、未經修改的檔案(通常為 csv 檔)，並根據裡頭的典藏號在各平台爬蟲，最後把爬來的內容更新到我們的 OD 資料庫。

- API 使用教學

  API 的資料夾架構如圖一，在使用時，請讓主程式和 CrawlerAPIUsageExample.py 在同一個資料夾。

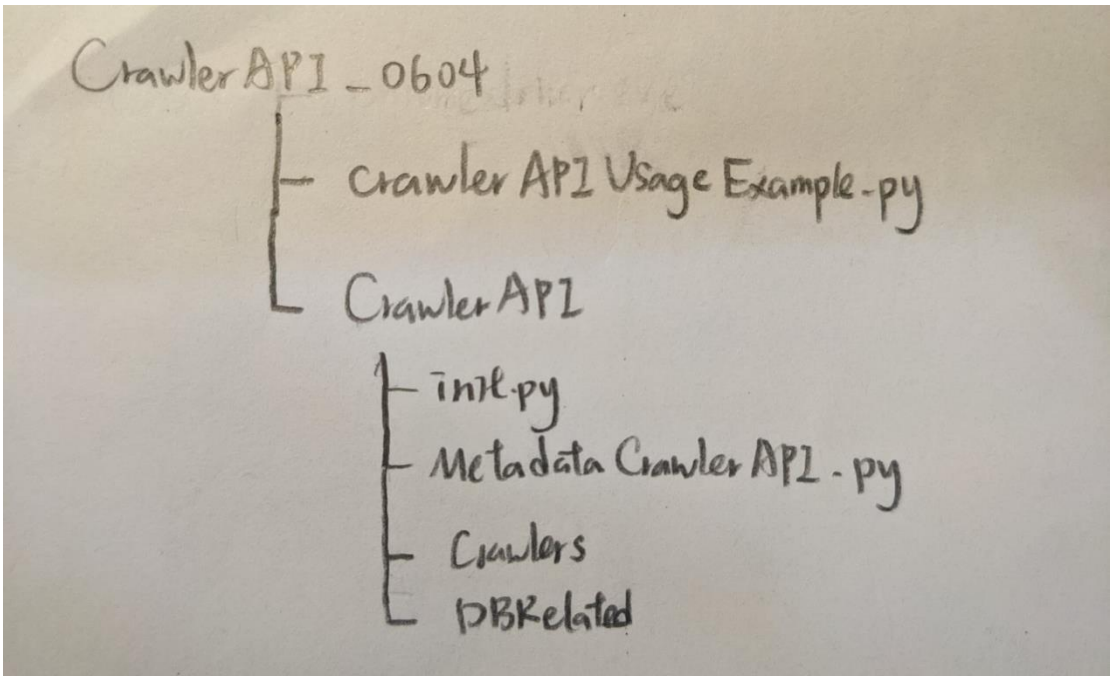

(圖一，API 資料夾架構圖)

此 API 以 function call 的方式使用。分成三個部分，分別是「判斷史料平台」、「提取典藏號」與「由典藏號爬蟲」，以下就分這三部分介紹。

- 判斷史料平台

  使用者會從從史料平台下載需要的資料(通常為 csv 檔案)，此部分就是從此 csv 檔案判斷是由哪一個爬蟲來處理。

```
WebAbbr = IdentifyWebAbbr(FilePath)
```

  - Input: FilePath 使用者下載下來的檔案路徑，資料型態為 string。
  - Output: WebAbbr 網站的英文縮寫，資料型態為 string。若失敗，

會回傳 False。

- 提取典藏號

  延續上個部分，從此 csv 檔案提取需要的全部典藏號，並一起輸出。

```
ids = InputToIDs(WebAbbr, FilePath, IsReturnJson)
```

  - Input: WebAbbr 網站的英文縮寫，資料型態為 string。
  - Input: FilePath 使用者下載下來的檔案路徑，資料型態為 string。
  - Input: IsReturnJson 預設值為 True。填是，回傳的資料型態會是 json，否則為 dictionary。
  - Output: ids 複數個典藏號，資料型態根據最後一個 input 有所不同。填是，為 json，否則為 dictionary。兩者的 key 皆為 0~長度-1，value 則為典藏號(string)。若失敗，會回傳 False。

- 由典藏號爬蟲

  延續上個部分，把典藏號一個個放到此部分，就會執行爬蟲，並把所得資料存到資料庫。

```
primaryKey = Crawling(WebAbbr, id)
```

  - Input: WebAbbr 網站的英文縮寫，資料型態為 string。
  - Input: id 單一典藏號，資料型態為 string。
  - Output: primaryKey 資料在 DB 中的唯一 ID，也是 primary key，資料型態為 int。

在 CrawlerAPIUsageExample.py 此檔案中，也有使用此 API 的方式可以參考。

- API 架構介紹
  架構圖如圖二。

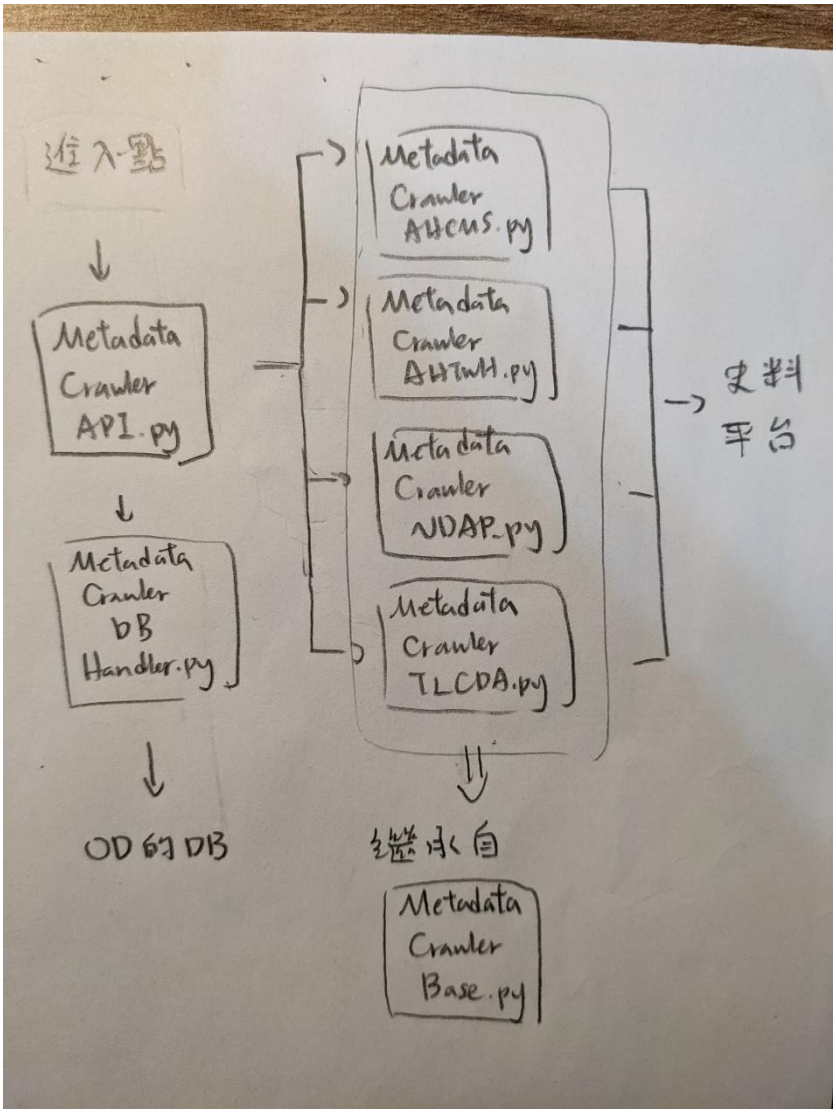

(圖二，API 架構圖)

首先是使用 API 的進入點，也就是引用的 MetadataCrawlerAPI.py，他會呼叫 MetadataCrawlerDBHandler.py 來間接操作 OD 的資料庫，也會使用不同的 MetadataCrawlerXXX 來判斷史料平台、提取典藏號與爬蟲。而這些 MetadataCrawlerXXX 都是繼承自 MetadataCawlerBase。

- API 新增「支援的史料系統」教學
  若想要新增支援的史料平台，就必須為了此平台寫客製化的程式，再把此程式合成到此 API 中。步驟如下
  - 新增一個 python 檔案到 CrawlerAPI/Crawlers/底下，並宣告一個 class 繼承 MetadataCawlerBase。
  - 根據該史料平台覆寫 MetadataCrawlerBase 中的函式。

- IdentifyCSV: 判斷使用者下載下來的資料是否為此 Crawler 所處理的網站。回傳 bool。
- InputToIDs: 從使用者下載下來的資料，提取其中複數個典藏號。回傳 list of string。
- IDCrawling: 根據典藏號來爬蟲。回傳 dictionary 來存放資料。
- DataCleaning: 從網站直接爬取的資料，需要的資料清洗動作，像是去除空白鍵等等。回傳 string。
- DataLinking: 把上述的 dictionary 依照規範轉換成 list。此規範與 OD 資料庫的儲存方式有關，可以參考 CrawlerAPI/DBRelated/MetadataFormat。(舉例: 若爬下來的資料 A 屬於「原始時間記錄」欄位，則要把資料 A 擺放到 list 的第 7 格，也就是 list[6]中。)
  另外，OD 資料庫有些規定的事項要注意:
  - 第 12 欄位(文件原系統頁面 URL)，要填入爬蟲的網頁 URL。
  - 第 14 欄位(爬蟲 Original)，要填入爬到的原始資料(以 string of json 呈現)。
  - 15~18 欄位(相關人員、相關地點、相關組織、關鍵詞)要以半形分號(;)來做分隔。

- 在 CrawlerAPI/Crawlers/MetadataCrawlers 中，添加新增的 class。

完成後即可，可以參考現有的四個 class 來寫，特別注意地方議會議事總庫(TLCDA)，由於網站上能爬到的資料比使用者能下載下來的還要少，所以相關的 crawler 並沒有實際的爬蟲作用。